从 IC 检验到负向筛选：全市场 A 股多因子选股模型的可复现实证研究

From Information Coefficient to Negative Screening: A Reproducible Empirical Study on a Full-Market A-Share Panel

数据挖掘技术与应用课程项目组
中国石油大学（北京）克拉玛依校区
中国

ABSTRACT

本文构建一个覆盖 2016–2026 年、5,342 只 A 股、9,746,194 行、42 因子的日频面板，研究短周期收益排序的可预测性及其可落地形态。模型采用 LightGBM、3 种子 Transformer 与 Ridge 元模型，在 5 折 Purged + Embargo 交叉验证下取得 IC 0.1041 ± 0.0094（五折全正，ICIR 0.820）。然而十分位结构显示预测力高度集中于最差一档：D1 单档约 −10%/ 年，D2–D10 几乎平坦，高流动性半区中 D10 甚至为负——该模型是「避雷器」而非「选股器」。在 A 股无法融券做空个股的约束下，唯一可执行形态是剔除打分垫底 10% 的负向筛选，三段互不重叠区间年化超额 +5.85%、+4.67%、+2.87%（封存段，一次性）。我们进一步报告 8 条被证伪的建模路径、三类文本/事件切法的无效性，以及一个通过严格 CV 增量门的外来因子（缠论中枢位置，ΔIC = +0.0153，配对 $t = 9.92$，0/5 折下降，三个泄漏探针全部通过）。全部结论、负结果、35 项单元测试与运行日志均可追溯，并给出从原始数据到最终图表的一键复现流程。

CCS CONCEPTS

• **Information systems** → **Data mining**; • **Applied computing** → **Economics**; • **Computing methodologies** → *Machine learning*.

KEYWORDS

multi-factor stock selection, purged cross-validation, negative screening, A-share market, leakage control, reproducibility, factor incrementality

1 引言

短周期收益的可预测性是资产定价与数据挖掘共同关心的核心问题。已有研究在美股与 A 股上分别报告了机器学习模型对截面收益排序的预测能力 [3, 4]，但「IC 显著」与「可交易」之间仍隔着数道约束：交易成本、做空限制、换手约束，以及最容易被忽视的时间序列泄漏。本文的目标不是再提高一点 IC，而是回答一个端到端的问题：在真实市场约束下，一个显著的全市场排序模型能落地成什么形态，其贡献有多大，且这个结论能否被严格复现？

我们使用公开的行情、财报、业绩预告与 ST 日历构建异构数据面板，以 t 日收盘出信号、t+1 日收盘买入、持有 5 日的超额收益为标签，训练并严格验证多因子排序模型。研究贡献有三：

Conference'17, July 2017, Washington, DC, USA
2026. ACM ISBN 978-x-xxxx-xxxx-x/YY/MM
https://doi.org/10.1145/nnnnnnn.nnnnnnn

Table 1: 数据源、形态与规模

类别	形态	规模	用途
后复权日线	结构化表格	970 万行	42 因子
财报与指标	结构化表格	54 期 × 4 表	基本面
业绩预告	半结构化文本	91,126 条	分类、事件
ST / 行业 / 股东	结构化表格	15 万行以上	事件、画像

(1) 规模与口径：给出一套覆盖 5,342 只股票（含退市名单以抑制幸存者偏差）、2,622 个交易日、42 因子的后复权面板，并把复权断层、停牌、路径依赖指标的时间对齐写成可复用的治理规则。
(2) 严格的验证纪律：5 折 Purged + Embargo CV（purge/embargo 各 6 日、expanding 窗口、固定轮数不逐折选参）加一次性封存段；所有可训练组件逐折重拟合；任何「加因子」必须过 CV 增量门。
(3) 负结果与可复现性资产：系统报告 8 条被证伪路径、事件研究三种切法的无效性、以及三类外部因子复现的结论；交付 35 项单元测试、逐脚本运行日志与 4.6 秒可跑通的 Notebook。

2 相关工作

多因子与机器学习资产定价。Fama–French 三因子 [1] 与 Amihud 流动性度量 [2] 奠定了截面因子框架；Gu 等 [3] 系统比较了机器学习方法在美股收益预测上的表现。LightGBM [4] 与 Transformer [5] 分别代表树模型与序列模型两条主线。本文在此基础上把重点放在 A 股约束下的落地形态而非模型容量。

金融时序的验证与泄漏。Purged K-Fold 与 embargo [6] 用于处理标签窗口重叠；本文把该协议扩展到「所有可训练组件逐折重拟合」，并额外处理路径依赖型结构因子的状态映射泄漏。B6 类的「重复验证」问题（同一批样本被同时标为 dev-val 与 dev-OOS）也在本文中显式排除。

可解释性与规则挖掘。Apriori [7] 与 FP-Growth [8] 用于发现极端状态组合；SHAP [9] 用于全局与局部归因。持续学习与状态自适应方面，ReCAP [12] 提出按市场状态切分并持续更新策略库，本文以独立环境复现其 DOW30 流程作对照。

3 数据集与数据治理

3.1 异构数据源

融合后有效记录 9,746,194 行，主分析表 42 字段，跨 3 张以上表关联；交付 110 字段数据字典（含缺失率、单位、取值范围、来源与时点）与逐数据集的数据溯源档案。

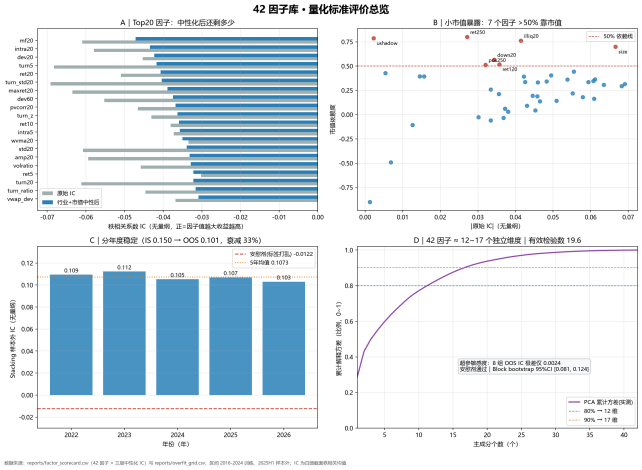


Figure 1: 42 因子打分卡。数据来源：本项目面板，**2016–2025**。

3.2 三条决定性口径

后复权（**hfq**）。东财 A 股前复权采用「减法复权」，会把贵州茅台历史价调成 −143.50 元；负价区间的收益符号反转，足以毁掉全部动量类因子。本项目一律使用后复权。

复权断层的制度反查。相邻日收益若超出涨跌停制度上限（主板 ±10%、创业板 2020-08 后 ±20%、科创板 ±20%、北交所 ±30%）加 2 个百分点，且不属于新股前 5 日或长停复牌，则判为数据断层。处理分三层：断层日收益置空；跨断层的 5 日前向标签作废；回看型因子（$ret5/10/20/60/120/250$、$dev20/60$、$pos250$、$momq60$、$wvma20$）在窗口跨断层时置空。绝对收益统一取自己清洗的收益矩阵，不各自从收盘价重算。

防泄漏。标签定义为 $Y_2 = close_{t+6}/close_{t+1} - 1$ 后截面去均值；训练目标用 rank 变换 $(rank - 0.5)/n$。验证采用 6 块 expanding 切分、purge 6 日、embargo 6 日、5 折；LGBM、Ridge 线性基线、因子 ICIR 权重与 Stacking 元模型全部逐折重拟合；重采样、标准化、特征选择仅在训练折内进行；封存段 2025-07~2026-10 只在开发结束后打开一次。

4 方法

4.1 因子与模型

42 个因子中最强的是资金加权收益 `mf20`（OOS IC −0.073）、成交额扩张 `amt_ratio`（−0.068）与流动性恶化 `illiq_ratio`（+0.053）。增量实验表明：仅 12 个量价因子即达到旧 30 因子集约 92% 的效力，合并后 IC 仅提升约 0.003，却使因子合成基线 IC 从 0.0411 升至 0.0550（+34%）。

模型采用 LGBM（best_iter = 85）、3 seed Transformer（40 日 × 42 因子序列）与 Ridge 元模型 Stacking。对照实验显示 rank 回归（IC 0.112）优于 pairwise（0.108）与 BCE（0.084）。需注意 Stacking 元层在 5 折上为负贡献（−0.0045），因此报告只把 dev 段 0.1316 作为内部结果，不作为独立样本外证据。

4.2 落地形态与评估指标层级

评估遵循四级递进判定：$IC \to D1$ 命中率 → 全市场 $D1$ 桶 → 组合年化超额。单看代理指标会互相矛盾：某次尾部加权实验在 IC 口径上判为无效（−0.0003），换成 D1 命中率却改善 3.3pp，

Table 2: 5 折 **Purged CV** 与 **dev** 段结果

指标	数值	备注
面板	9,746,194 行	2,622 日 × 5,342 只
LGBM dev IC	0.1285	best_iter 85
Stacking dev IC	0.1316	Ridge 元模型
5 折 **CV IC**	**0.1041 ± 0.0094**	五折全正
ICIR	0.820	日频 IC 均值/标准差

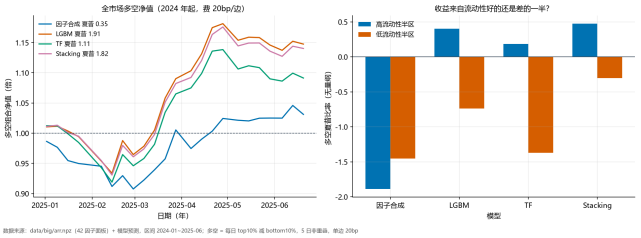


Figure 2: 模型评估：逐折 **IC** 与多空组合。数据来源：本项目 **5** 折 **CV**，**2016–2025**。

Table 3: 剔除垫底 **10%** 的年化超额（**5** 日调仓，单边 **15bp**）

区间	年化超额
2024（meta 段）	+5.85%
2025H1（dev 段）	+4.67%
2025-07 ~ 2026-10（封存段）	+2.87%

而全市场对照显示避损反而变差，最终组合年化 −0.38pp 且不显著。因此本文以组合层面的年化超额为终局指标。

落地公式明确为：持有宽基/等权组合，按模型打分剔除垫底 10%，5 日调仓，单边 15bp。组合超额按 $\frac{n}{N-n}$ 的剔除比例对 D1 与全市场均值之差折算，避免早期实现中把 $-\text{mean}(D1)$ 直接当年化而虚增到 +53% 的错误。

5 实验

5.1 主结果

十分位结构解释了模型本质：D1 单档约 −10%/ 年，D2–D10 几乎平坦，高流动性半区中 D10 为 −1%。多空 13pp 价差中约 10pp 来自「避开 D1」。纯多头 top10% 超额 −2.9% ~ −5.4%，而剔除垫底 10% 的超额为 +3.3% ~ +3.7%，波动仅 1.7%。

5.2 禁买清单：三段互不重叠验证

三段超额单调衰减，信号在减弱但始终为正。一处口径修正值得记录：原实现用 DataFrame 行索引计算名单更替，跨日索引不重叠导致每期恒为「100% 更替」、成本多扣约 1.7bp/期；改用股票代码后真实更替 44%，各段数字上修约 0.8pp，旧结果留档可查。

5.3 数据挖掘方法横向结果

关联规则。 Apriori 与 FP-Growth 产出完全相同的 30 条规则，后者快 4.7 倍。9 组阈值敏感性分析后，规则按「同前件且后件为子集」去重并剔除平凡规则，归为五族：偏离均线 + 高波动（lift 2.49）、振幅扩张 + 日内强势（2.42）、近期涨停 + 高于

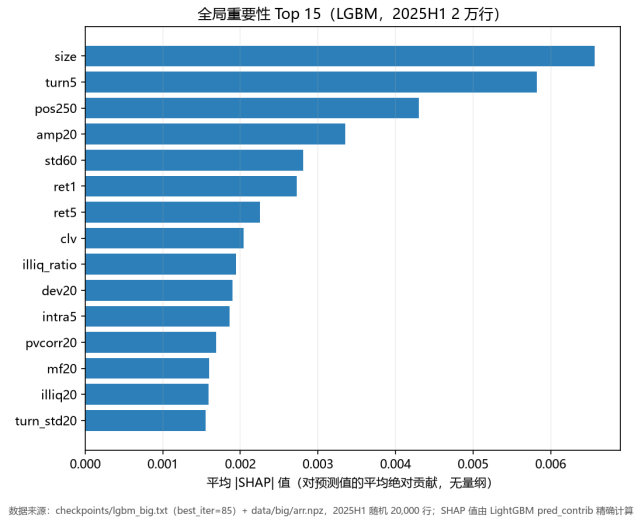


Figure 3: SHAP 全局重要性。市值 **11.6%**、**5** 日换手 **10.3%**、**250** 日位置 **7.6%**。数据来源：本项目 **LGBM TreeSHAP**。

成本（2.40）等。`illiq` 在 184 条原始规则中仅出现 9 次，却在 ICIR 线性加权中占 67% 权重——线性加权要单调排序、关联规则要极端子集，两者互补。

分类。在 2,398 训练 / 602 评估的公告情感任务上，分层 5 折与超参搜索后：结构化字段 93.2% > BERT 89.2% > LR 88.2% > Qwen3-0.6B SFT 87.9% > 10 行正则 84.6% > Laya 冻结微调 78.7%。错误样本解剖显示，大模型在「正文明确写出预增/预减」的 90% 样本上输给字符串匹配，只在「正文不写方向」的 9.5% 样本上领先（66.7% vs 47.4%），瓶颈是任务定义而非容量。不平衡处理中类别权重最优（macro-F1 0.891，中性召回 0.90），SMOTE 无额外收益。

聚类。4,914 只 × 42 因子画像，肘部拐点 $k = 4$、轮廓系数最优 $k = 2$；高维下轮廓系数随 k 单调下降，故以 bootstrap ARI 裁决：$k = 4$ 时 0.963（稳定），$k = 31$ 时仅 0.392——现用行业 31 组在重抽样下约三分之一标签会变。

可解释性。全局前三为 `size` 11.6%、`turn5` 10.3%、`pos250` 7.6%；线性口径给 `illiq_ratio` 36.9% 权重，SHAP 中仅排第 9（3.4%）。这一差异说明树模型主要把流动性维度用于交互而非主效应。

事件研究。采用 CAR + 同股票安慰剂分位 + 同侪对照三件套：财报 SUE 极端 5 日 CAR −1.49%（$t = -2.62$），业绩预告 −0.58%（$t = -0.83$），ST 摘帽 250 日 CAR −13% 但安慰剂分位 40%（非事件效应）。进一步以「公告 vs 卖方 FY2026 一致预期」偏离度检验 275 个匹配事件，五分位 Q5−Q1 在 5/20/60 日为 −1.82%/−1.73%/−3.39%，$p = 0.34 \sim 0.48$ 全不显著。业绩预告的三种切法（类型、文本、公告 vs 预期）均无交易级超额。

5.4 因子复现与增量检验

缠论案例值得展开。我们实现合并 K 线 → 分型 → 笔 → 中枢 → 背驰共 10 个因子。笔幅度与中枢宽度与既有 `dev20/std60` 高度相关（0.64），残差归零；唯一有增量的是「中枢内相对位置」：控制中期动量后残差 IC +0.0115、9 年全正、五分位 Q5−Q1 年化 +15.2%。

按项目规矩，加因子必须过 CV 增量门。我们在全市场 5,342 只上重算该因子，以完全相同协议跑三臂：A 基线（42 因子）、B 加原始值、C 加逐日截面回归剔除 `momq60/ret60` 后的残差。结果 A 逐折 IC 与正式 `purged_cv.py` 完全一致（0.1041 ± 0.0094，验证协议复现无误），B 为 0.1194（Δ + 0.0153，配对 $t = 9.92$，0/5 折下降），C 为 0.1086（Δ + 0.0045，$t = 5.54$）。由于「好得不像真的」，另做三个泄漏探针：股票维度列置乱与滞后 60 日均使 IC 退回基线（$\Delta \approx -0.015$），而把因子提前 10 日（覆盖标签窗）使 IC 跳到 0.2843。三者共同排除对齐泄漏，确认 +0.0153 为真实增量。条件 IC 拆解进一步显示其价值来自与动量的交互：高动量组内 IC −0.032，低动量组 −0.004，而「低动量 × 站上箱体上沿」为 +0.014——这正是线性因子表达不了、树能切出的结构。该因子目前尚未入库：入库需重跑全管线并重估禁买清单，而封存段已消耗。

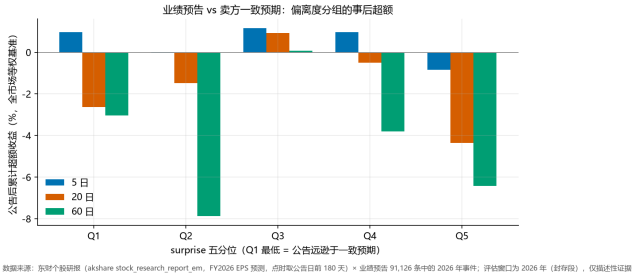


Figure 4: 公告 **vs** 一致预期偏离度的五分位事后超额。数据来源：东财研报 × 业绩预告，**2026** 年。

Table 4: 外部因子复现与对照实验

对象	做法	结论
WQ101 价量背离	复现 + 相关/增量	IC 0.051，九成被 `pvcorr20` 解释，不入库
缠论结构	分型/笔/中枢/背驰 + 全市场 5 折 CV	中枢位置 ΔIC = +0.0153，$t = 9.92$，0/5 折下降
ETF 三因子	固定池 vs 事前动态池	动态池 −2.4% vs 固定池 +10.2%，原文系事后挑池
国家队跟随	23 期、4 基准	−4.6pp（$p = 0.220$），增持信号无效
TAA v3	12 变体 + 卫星腿	夏普 0.49 vs 0.93，三种用法均不成立
ReCAP (KDD'26)	独立 venv，DOW30	跑通；持续更新使 CR 由 −99.3% 收窄至 −55.1%

5.5 被证伪的路径

八条路径全部无增量：SVM 日频/截面、多空组合（封存段 −1.08%）、纯多头 top10%、行业动量追涨（0 成本 −5.88%/年）、基本面因子加成（5 折中 4 折变差）、Muon 优化器（与 AdamW 持平）、策略轮动（12 变体全输固定配置）、行业中性化（申万一级/聚类 31/聚类 4 三种分组均使 CV 下降 0.4~0.6pp）。此外记录三处工程教训：合并 K 线组内提前使用状态使残差 IC 从真实 +0.0115 虚增到 +0.0220；SFT 批量生成因右 padding 让

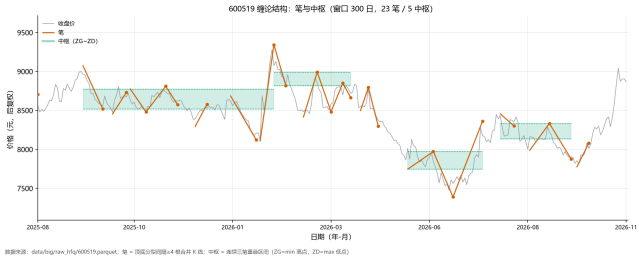


Figure 5: 缠论结构示意（合并 **K** 线、分型、笔、中枢）。数据来源：新浪财经日线。



Figure 6: ETF 三因子动量轮动：动态池与固定池对照。数据来源：新浪 **ETF** 日线、同花顺名单。

decoder 从填充符续写，准确率仅 11.6%，逐条生成后 87.9%；用当年画像给当年分组造成前视偏差（+0.1326 假象，改上年画像后 +0.1014）。

6 讨论

为什么模型只能做减法？十分位结构给出的解释是：A 股短周期的可预测性主要来自崩盘风险而非上涨空间。D1 集中了几乎全部负向信息，而 D10 在高流动性半区甚至掉到 −1%。这与「个人投资者占比高、壳价值与题材炒作使极端下跌更可预测」的市场结构一致。

为什么必须有多级指标？我们在尾部加权实验中观察到代理指标互相矛盾：IC 判无效、D1 命中率改善 3.3pp、全市场对照显示避损变差、组合年化 −0.38pp 不显著。只有走到组合层终局指标才能定案。类似地，「加因子」不能凭单因子 IC 为正就入库，必须做 CV 增量检验——WQ101 价量背离（IC 0.051）就是反例，而缠论中枢位置（原始 IC −0.024）反倒通过增量门，说明树模型吃的是交互而非线性方向。

7 效度威胁与局限

(1) 封存段已消耗：2025-07~2026-10 的一次性验证已用掉，此后任何新模型（包括 43 因子版）无法再做独立验证，只能以 CV 为唯一外部锚。
(2) 超额衰减：+5.85% → +4.67% → +2.87% 单调下降，信号拥挤度上升。
(3) 成本假设：20bp/边能活、50bp/边即 −31.4%/年；实盘应按 30bp 准备，且未完整建模涨跌停不可交易与冲击成本。
(4) 行业口径：面板存申万二级 128 类，评估统一用申万一级 31 类（覆盖 97.1%）；ARI 0.392 表明细粒度分组不稳定。
(5) 数据缺口：减持公告受接口限流不可得，以业绩预告替代；卖方一致预期仅覆盖机构关注的标的（12%），且只有 3 个绝对年份的预测，无法构建可靠的点时历史预期面板。
(6) 文本任务的标签：公告方向由强制披露字段决定，与「次日超额」标签一致率仅 35.7%，换标签后全部模型准确率 34~36%，也说明该文本任务本身信息量有限。

8 可复现性

全部 125 个脚本、35 项单元测试（每个对应一个真实 bug）、`requirements.txt`、固定随机种子（LGBM seed = 42、TF 3 seed bagging）、逐脚本运行日志（时间戳、参数、硬件、耗时、状态）与 4.6 秒可跑通的 Notebook 均随项目交付。换机器重跑，IC 差 0.0005。完整重跑命令：面板约 40 分钟、训练约 25 分钟、5 折 CV 约 10 分钟。所有图表统一中文坐标轴、单位、图题与数据来源脚注，采用色盲友好配色。

```
python scripts/big_features.py    # 面板
python scripts/big_train.py       # 训练
python scripts/purged_cv.py       # 5 折 CV
python scripts/chan_cv.py         # 因子增量三臂
python scripts/chan_cv_probe.py   # 三个泄漏探针
python scripts/live_screen.py     # 当期禁买清单
```

9 结论

在一个 970 万行、42 因子的全市场 A 股面板上，我们得到 5 折 CV IC 0.1041 ± 0.0094，但证明其预测力集中在最差一档。受做空与成本约束，唯一可落地形态是剔除垫底 10% 的禁买清单，年化贡献 +3 ~ 5% 且单调衰减。我们系统报告 8 条被证伪路径与多类无效事件切法，并给出本项目第一个通过 CV 增量门的外来因子及其三个泄漏探针。本文的核心结论不是「模型有多强」，而是：在真实约束下，把验证纪律做对之后，剩下的可交易价值往往只有一点点，且必须靠负向筛选才能兑现。

REFERENCES

[1] E. F. Fama and K. R. French. 1993. Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics* 33, 1 (1993), 3–56.
[2] Y. Amihud. 2002. Illiquidity and stock returns. *Journal of Financial Markets* 5, 1 (2002), 31–56.
[3] S. Gu, B. Kelly, and D. Xiu. 2020. Empirical asset pricing via machine learning. *Review of Financial Studies* 33, 5 (2020), 2223–2273.
[4] G. Ke et al. 2017. LightGBM: A highly efficient gradient boosting decision tree. In *NeurIPS*. 3146–3154.
[5] A. Vaswani et al. 2017. Attention is all you need. In *NeurIPS*. 5998–6008.
[6] M. Lopez de Prado. 2018. *Advances in Financial Machine Learning*. Wiley.
[7] R. Agrawal and R. Srikant. 1994. Fast algorithms for mining association rules. In *VLDB*. 487–499.
[8] J. Han, J. Pei, and Y. Yin. 2000. Mining frequent patterns without candidate generation. In *SIGMOD*. 1–12.
[9] S. M. Lundberg and S.-I. Lee. 2017. A unified approach to interpreting model predictions. In *NeurIPS*. 4765–4774.
[10] J. Devlin et al. 2019. BERT: Pre-training of deep bidirectional transformers. In *NAACL-HLT*. 4171–4186.
[11] Z. Kakushadze. 2016. 101 formulaic alphas. *Wilmott Magazine* 84 (2016), 72–81.
[12] C. Pan et al. 2026. Regime-Adaptive Continual Learning for Portfolio Management. In *Proc. KDD 2026*. arXiv:2606.00143.